

Medimos hasta dónde aguanta gratis.

Pusimos una app real, cuatro microservicios en Go con conexiones en vivo, sobre la **capa gratuita de Render** y le echamos encima hasta mil usuarios simulados a la vez. Esto es lo que encontramos, para que no lo descubras tú en producción un domingo.

100

usuarios a la vez, **cero errores** y menos del 10 % de la memoria en uso

1 de 4

conexiones en vivo **se caen** al llegar a mil usuarios simultáneos

46.6 %

de la memoria usada **al momento de fallar**: le sobraba más de la mitad

Esperábamos que se muriera de falta de memoria. **Se murió de acoplamiento.**

Composición de sesiones WS a 1 000 VUs (rep. 1)

Completadas	3 528 (76.1 %)
Caidas	1 106 (23.9 %)

RAM pico por servicio: 100 → 1 000 VUs

Servicio	RAM pico (MB)
api-gateway	238 MB
realtime	231 MB
groups	55 MB
habits	22 MB

Lo que se rompe:

de cada cuatro personas que abren la app a la vez, una pierde la conexión en vivo.

¿Por qué, entonces?

Cada vez que alguien abre una conexión en vivo, ese servicio le pregunta a otro «¿esta persona pertenece a este grupo?». Correcto en seguridad, pero amarra el tiempo real a la velocidad de la base de datos: cuando esa consulta se atora las conexiones caen, y cada reintento vuelve a pegar sobre el mismo servicio saturado. **El cuello de botella estuvo en cómo amarramos las piezas.**

Lo que sobra:

el espacio a la derecha de los puntos es memoria sin usar. El límite nunca se tocó.

Lo que de verdad te va a doler

Te suspenden por datos, no por CPU

La cuota es de 5 GB al mes por cuenta. Nuestras pruebas movieron 17.8 GB y suspendieron dos. Comprimir bajó el tráfico 89.6 %.

El servicio se duerme a los 15 minutos

Despertar tarda 10–13 segundos por servicio. Encadenados, el usuario ve la app «caída» entre 30 y 60 segundos.

La base de datos también se pausa

Tras 8 días sin actividad la nuestra se pausó sola: los servicios arrancaban bien y fallaban en la primera consulta.

Rinde distinto según cómo la usaste antes

La base gratuita acumula «créditos» en reposo y los gasta bajo carga. Sin créditos: memoria al tope y procesador ocioso.

Qué haríamos distinto desde el día uno

1

Comprimir las respuestas

Lo más barato y lo único que medimos directo: 89.6 % menos datos en el cable.

2

No consultar la base en cada conexión

Cachear el permiso o firmarlo en un token rompe la cadena que nos tumbó.

3

Contar con el arranque en frío

Medio minuto en blanco duele más que 200 ms de lentitud. Avisa o despierta antes.

LETRA CHICA: LO QUE SÍ MEDIMOS Y LO QUE NO

- Medido:** 100 y 1 000 usuarios simultáneos, tres repeticiones cada uno.
- Es un caso, no una ley:** Go + Render + Supabase. Otra combinación puede romperse en otro lado.

- No probado:** planeábamos 2 500 y 5 000, pero las reglas del plan gratuito agotaron nuestra ventana de pruebas.
- Sin datos de personas:** toda la carga fue simulada contra una cuenta de prueba; no participaron usuarios reales.

- Estimado, no medido:** ~3 200 usuarios activos al día. Sale de un cálculo con supuestos declarados.
- Sesgo conocido:** los usuarios simulados compartían cuenta, así que la base de datos la tuvo más fácil que en la vida real.

dydi · Equipo 3 · Integradora 2026 · Universidad Tecnológica de Durango

García Páez David Israel · Solís Flores Irvin Alfonso · Cervantes Guerrero Keila Yuridia · Casiano Gamzi Juan David

El artículo completo, el arnés de pruebas y los datos crudos de las once corridas están publicados:

github.com/davidgarcia57/Dydi